Dense 使用同一组 FFN； MoE 选择执行路径

Dense FFN



所有输入使用同一组权重

Mixture of Experts

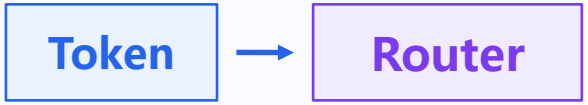
Dense 使用同一组 FFN； MoE 选择执行路径

Dense FFN



所有输入使用同一组权重

Mixture of Experts



Dense 使用同一组 FFN； MoE 选择执行路径

Dense FFN

Token → 同一组 FFN

所有输入使用同一组权重

Mixture of Experts

Token → Router

384 Routed Experts · 评分示意

Scores
0.12 · 0.91 · …

输入 权重 输出 传递梯度 权重梯度

Dense 使用同一组 FFN； MoE 选择执行路径

Dense FFN

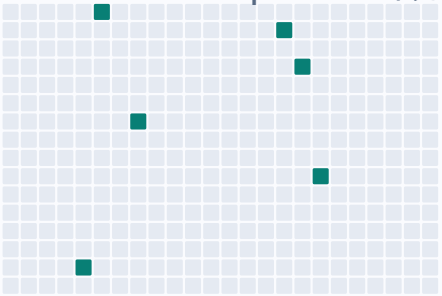
Token → 同一组 FFN

所有输入使用同一组权重

Mixture of Experts

Token → Router

384 Routed Experts · 评分示意



Scores
0.12 · 0.91 · …

Top-6

Dense 使用同一组 FFN； MoE 选择执行路径

Dense FFN

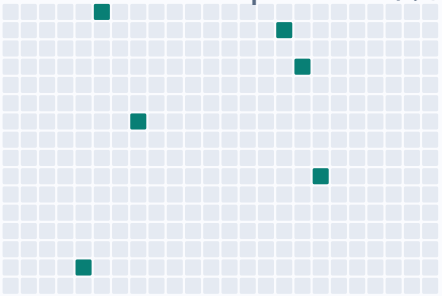
Token → 同一组 FFN

所有输入使用同一组权重

Mixture of Experts

Token → Router

384 Routed Experts · 评分示意



Scores
0.12 · 0.91 · …

Top-6

1 Shared

Dense 使用同一组 FFN； MoE 选择执行路径

Dense FFN

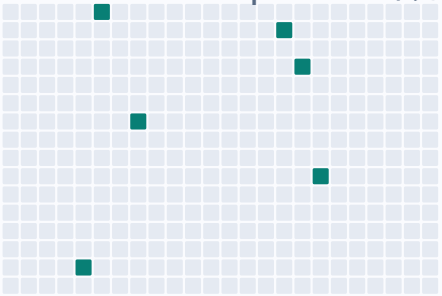
Token → 同一组 FFN

所有输入使用同一组权重

Mixture of Experts

Token → Router

384 Routed Experts · 评分示意



Scores
0.12 · 0.91 · …

Top-6

1 Shared

6 × Expert FFN

Dense 使用同一组 FFN； MoE 选择执行路径

Dense FFN

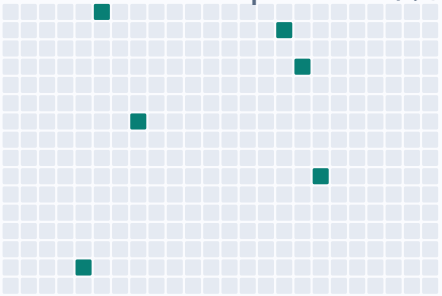
Token → 同一组 FFN

所有输入使用同一组权重

Mixture of Experts

Token → Router

384 Routed Experts · 评分示意



Scores
0.12 · 0.91 · …

Top-6

1 Shared

6 × Expert FFN

$\Sigma \alpha_i \, \text{Expert}_i(x) + \text{Shared}(x)$

输入 权重 输出 传递梯度 权重梯度

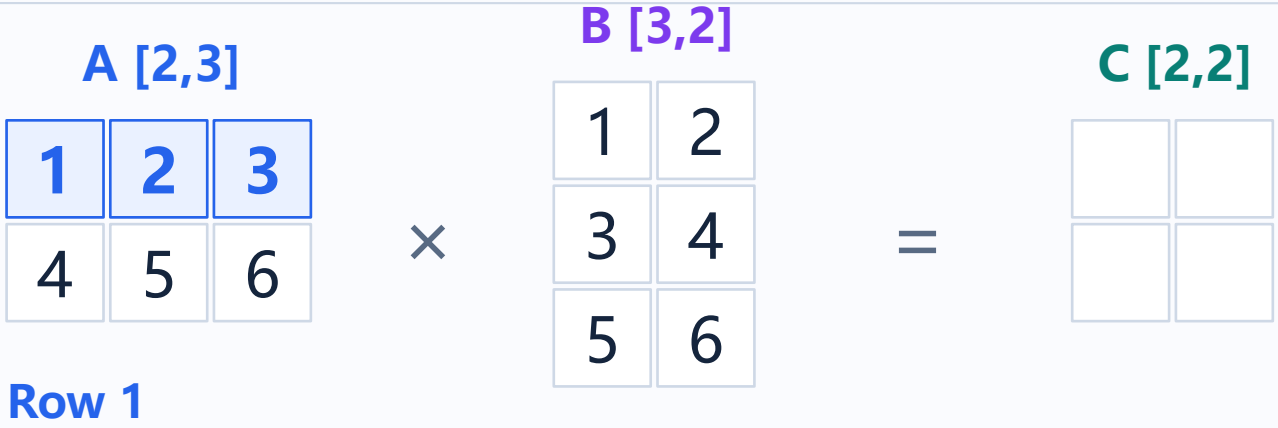
Matrix Multiplication： 一行 × 一列，生成一个数



每次只生成 C 中的一个元素

输入 权重 输出 传递梯度 权重梯度

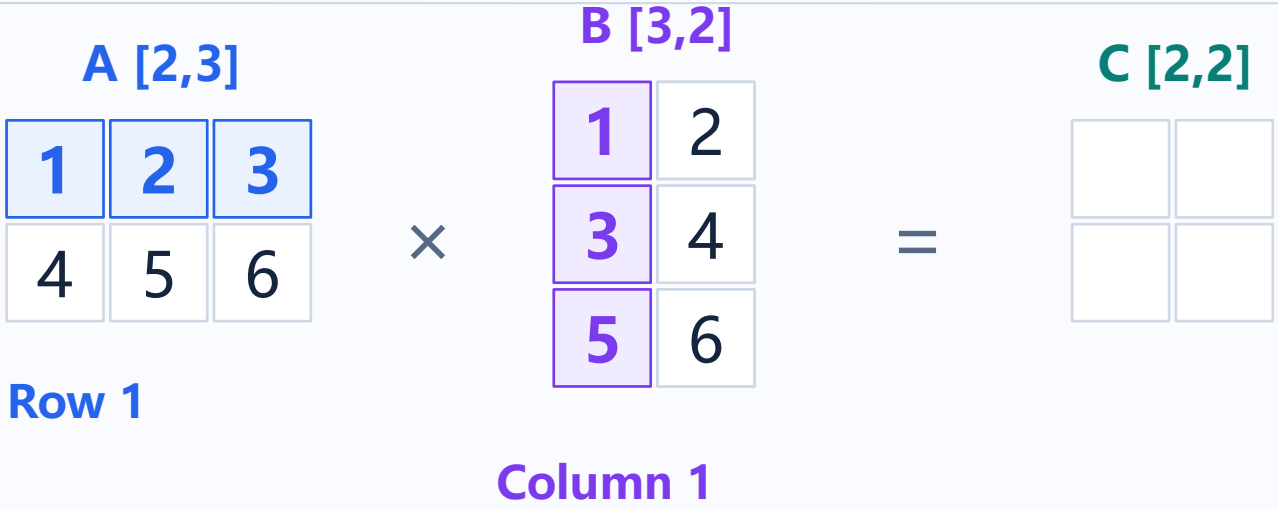
Matrix Multiplication： 一行 × 一列，生成一个数



每次只生成 C 中的一个元素

输入 权重 输出 传递梯度 权重梯度

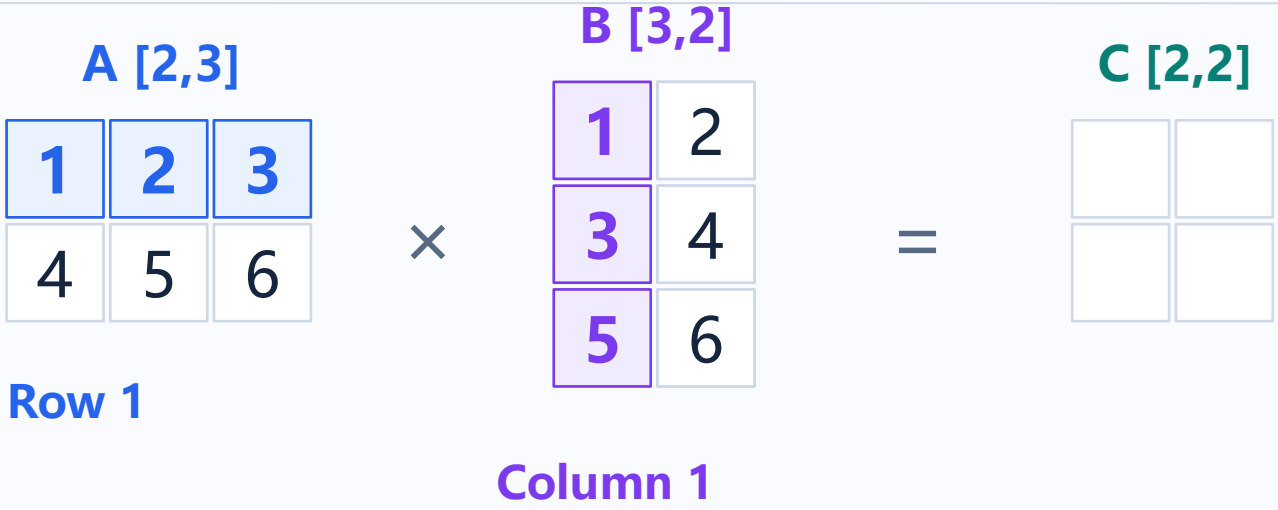
Matrix Multiplication： 一行 × 一列，生成一个数



每次只生成 C 中的一个元素

输入 权重 输出 传递梯度 权重梯度

Matrix Multiplication： 一行 × 一列，生成一个数



1 × 1 = 1

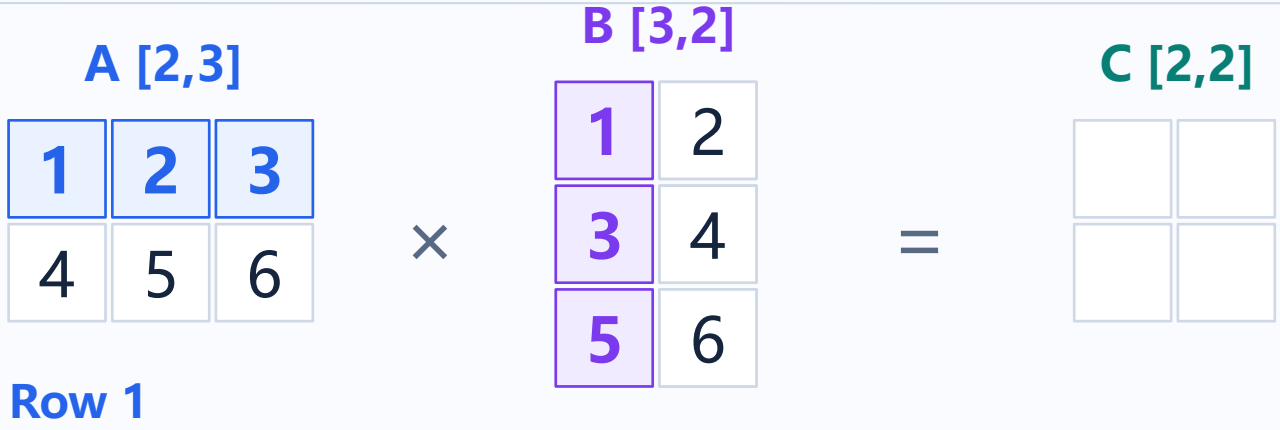
每次只生成 C 中的一个元素

Matrix Multiplication： 一行 × 一列，生成一个数



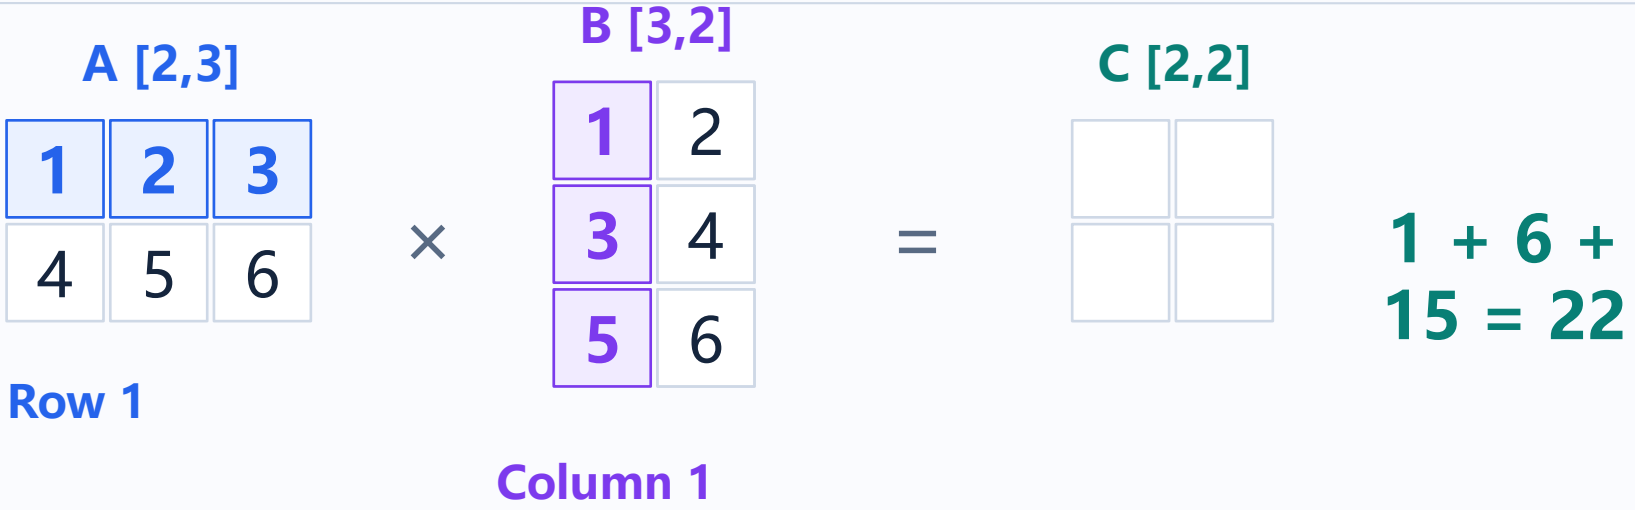
每次只生成 C 中的一个元素

Matrix Multiplication： 一行 × 一列，生成一个数



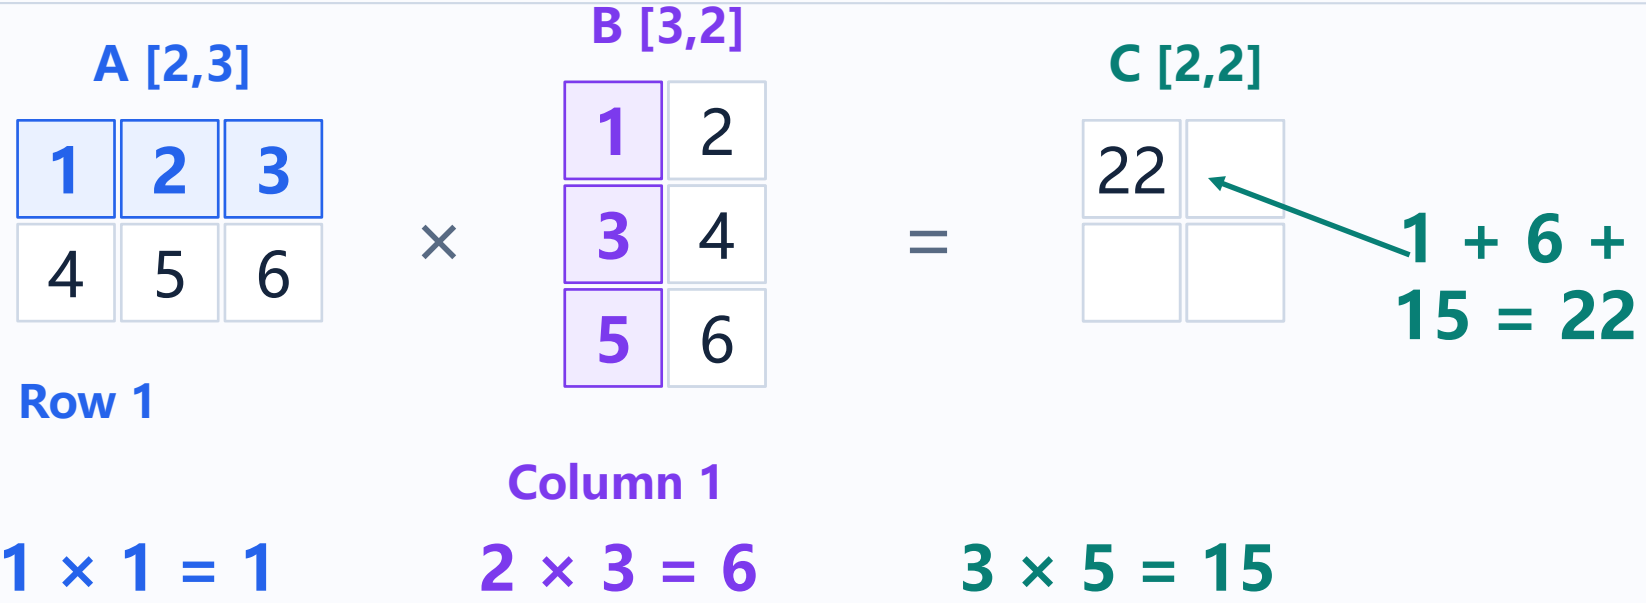
每次只生成 C 中的一个元素

Matrix Multiplication： 一行 × 一列，生成一个数



每次只生成 C 中的一个元素

Matrix Multiplication： 一行 × 一列，生成一个数



每次只生成 C 中的一个元素

换一列，得到下一个输出；重复同样的规则

A [2,3]

1	2	3
4	5	6

×

B [3,2]

1	2
3	4
5	6

=

C [2,2]

22	

换一列，得到下一个输出；重复同样的规则



输入 权重 输出 传递梯度 权重梯度

换一列，得到下一个输出；重复同样的规则



$$1 \times 2 + 2 \times 4 + 3 \times 6 = 28$$

换一列，得到下一个输出；重复同样的规则



$$1 \times 2 + 2 \times 4 + 3 \times 6 = 28$$

输入 权重 输出 传递梯度 权重梯度

换一列，得到下一个输出；重复同样的规则



$$1 \times 2 + 2 \times 4 + 3 \times 6 = 28$$

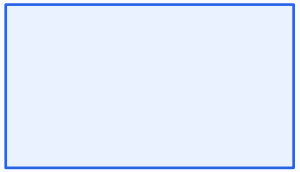
一个输出： K 次乘法 + (K−1) 次加法

本例精确： 4 × 5 = 20 FLOPs　　常用近似： 2MKN = 24 FLOPs

输入　权重　输出　传递梯度　权重梯度

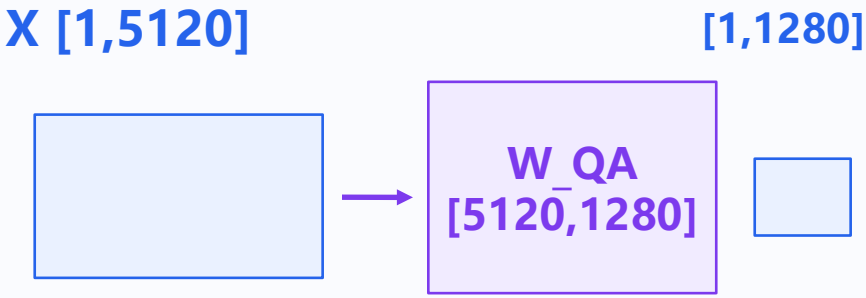
Query Low-Rank Projection： 先压缩，再展开

X [1,5120]



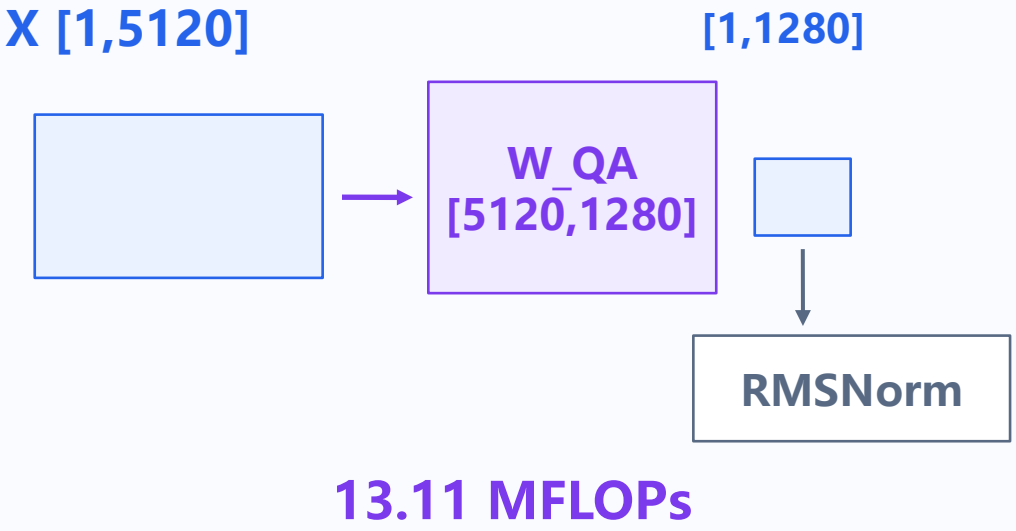
输入 权重 输出 传递梯度 权重梯度

Query Low-Rank Projection： 先压缩，再展开

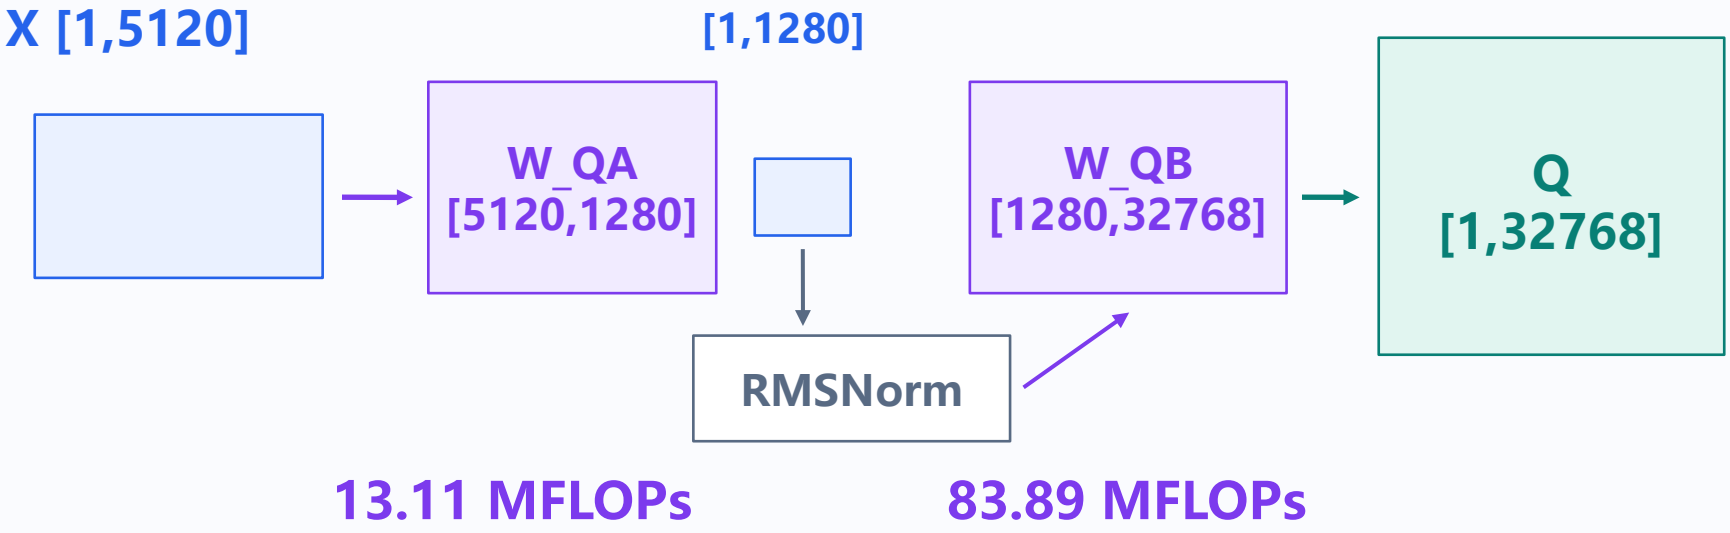


13.11 MFLOPs

Query Low-Rank Projection： 先压缩，再展开

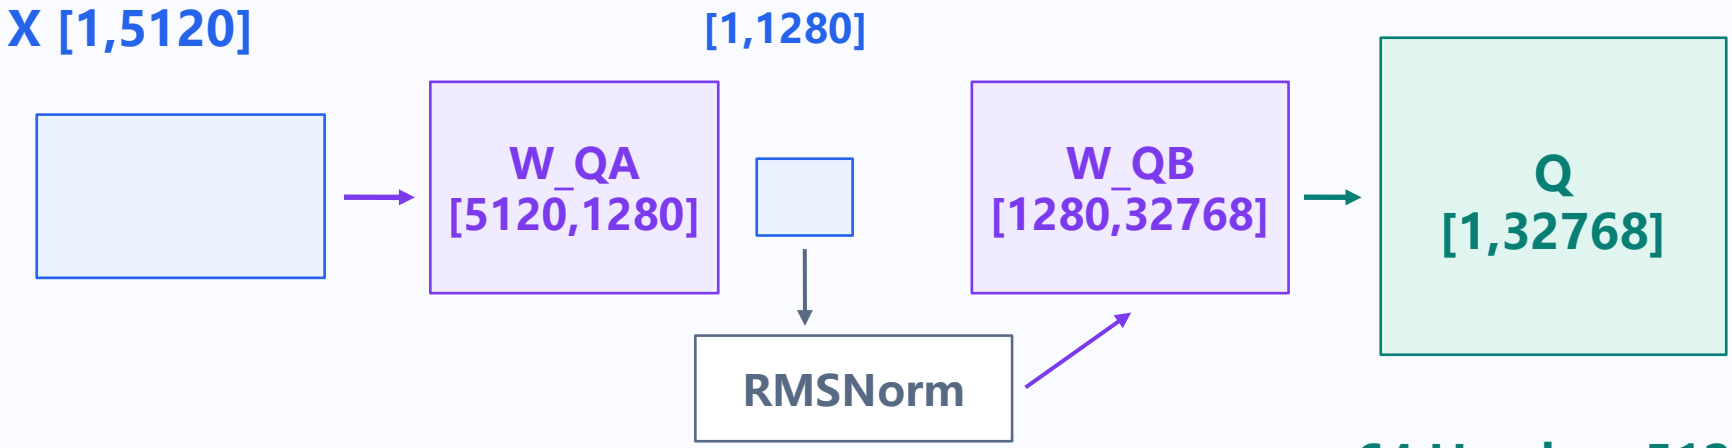


Query Low-Rank Projection： 先压缩，再展开



输入 权重 输出 传递梯度 权重梯度

Query Low-Rank Projection： 先压缩，再展开



两次 Linear 合计： 96.99 MFLOPs

宽度为示意； FLOPs 不含 RMSNorm / RoPE

输入 权重 输出 传递梯度 权重梯度

Forward 保存输入； Backward 沿图反向传梯度

输入 权重 输出 传递梯度 权重梯度

Forward 保存输入； Backward 沿图反向传梯度

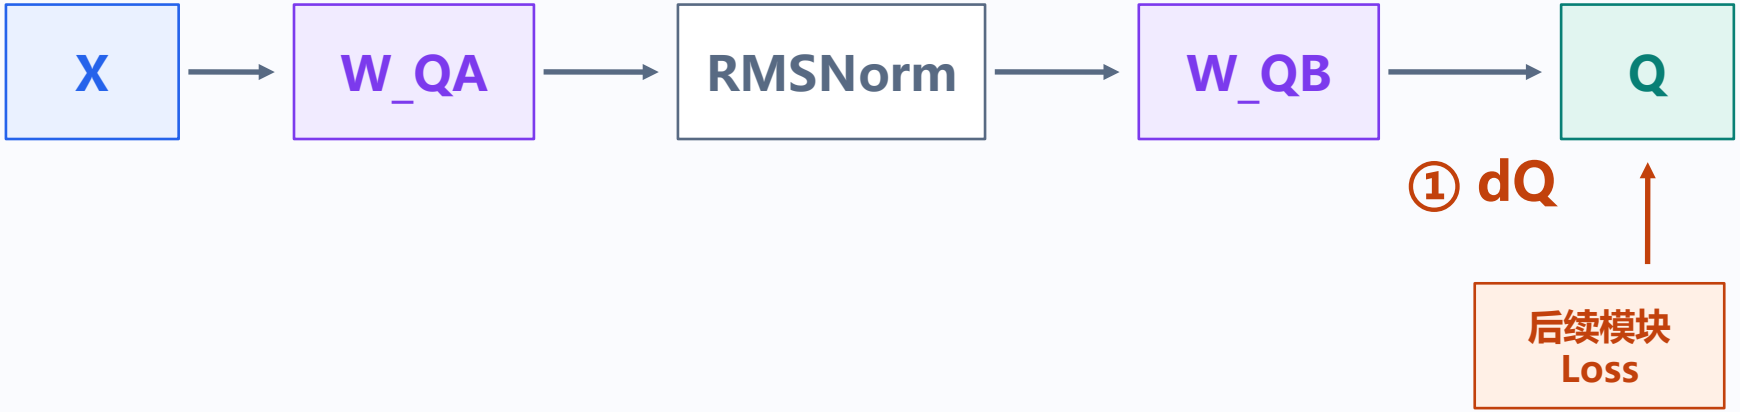
Forward → 保存 X 、 H 、 H′ 与各层权重



输入 权重 输出 传递梯度 权重梯度

Forward 保存输入； Backward 沿图反向传梯度

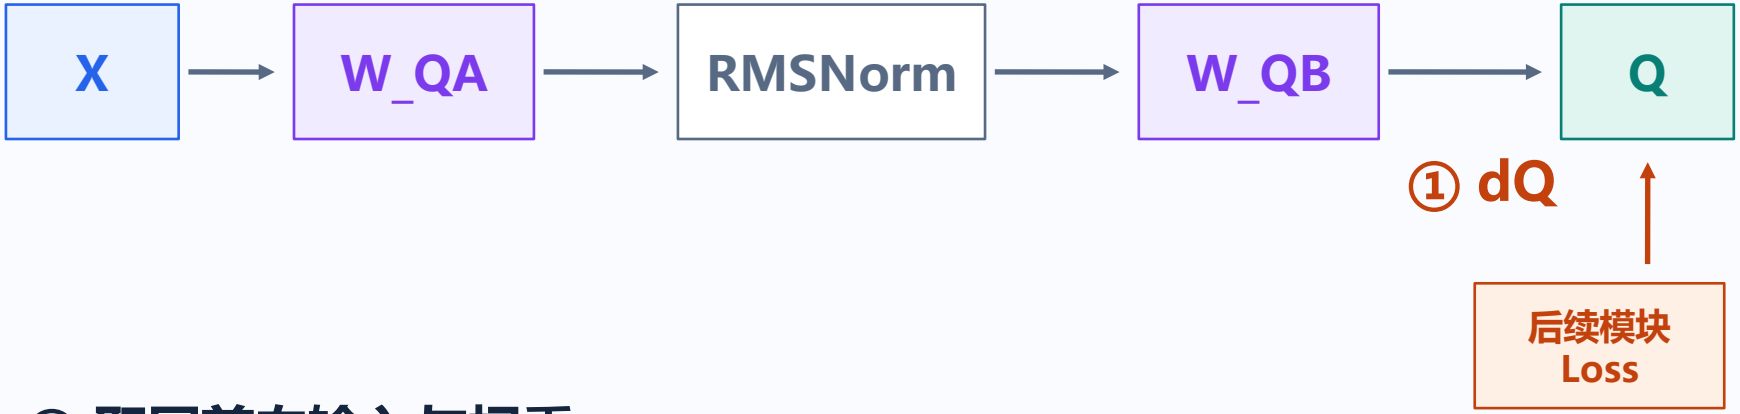
Forward → 保存 X 、 H 、 H′ 与各层权重



输入 权重 输出 传递梯度 权重梯度

Forward 保存输入； Backward 沿图反向传梯度

Forward → 保存 X 、 H 、 H′ 与各层权重

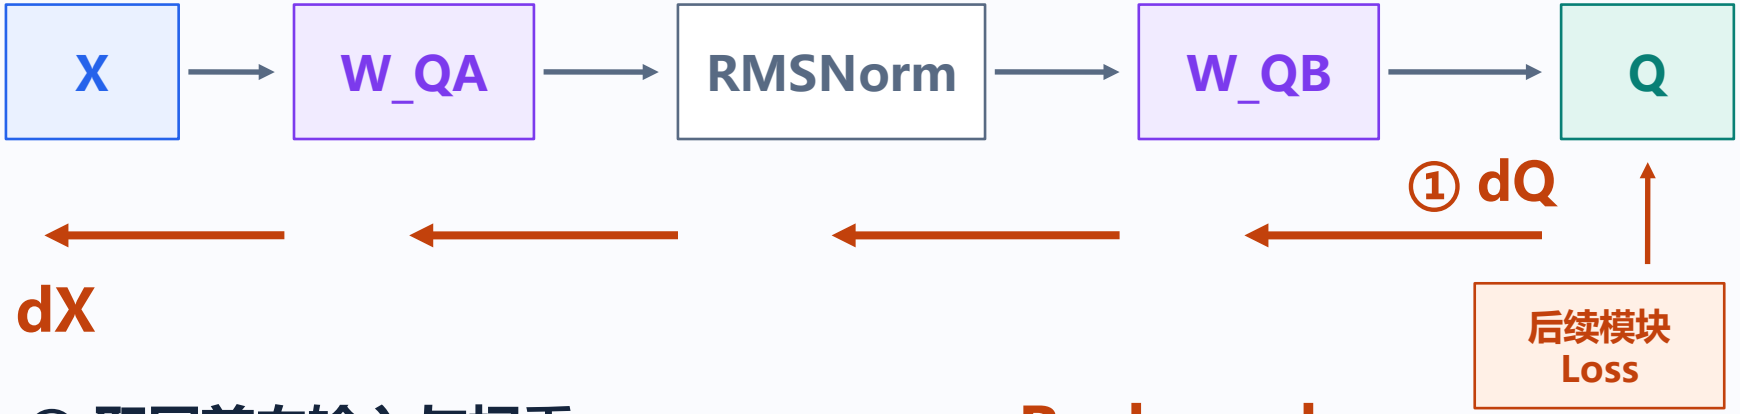


② 取回前向输入与权重

输入 权重 输出 传递梯度 权重梯度

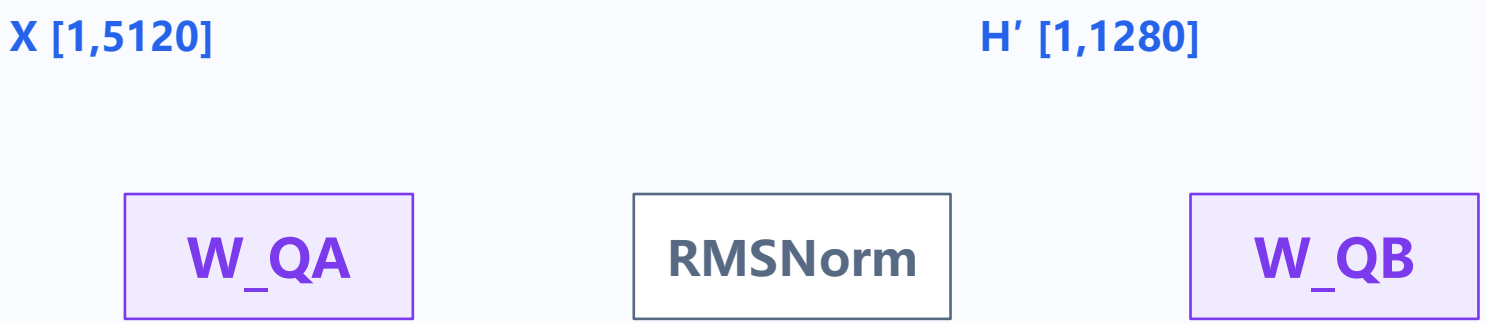
Forward 保存输入； Backward 沿图反向传梯度

Forward → 保存 X 、 H 、 H′ 与各层权重



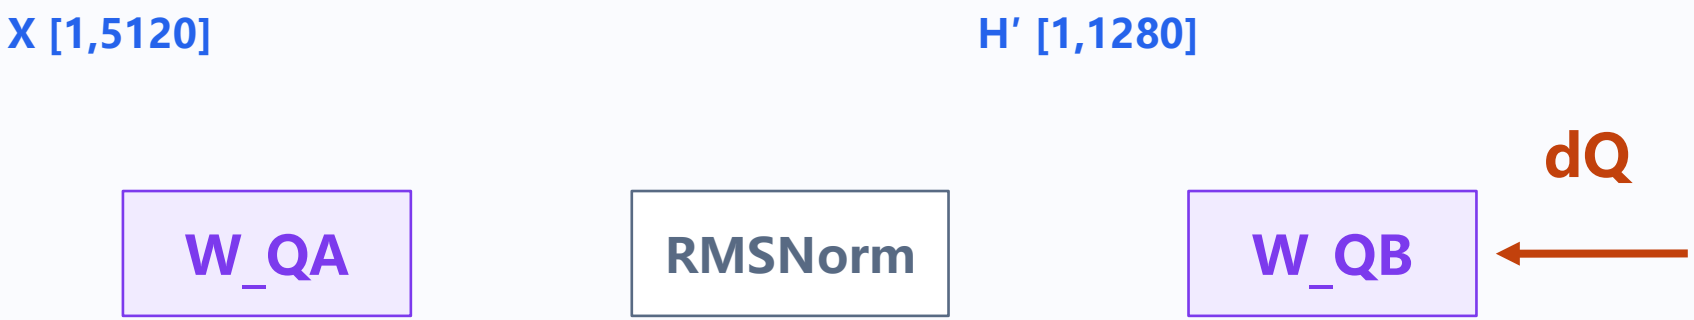
输入 权重 输出 传递梯度 权重梯度

每个 Linear 同时产生两种去向的 Gradient



输入 权重 输出 传递梯度 权重梯度

每个 Linear 同时产生两种去向的 Gradient

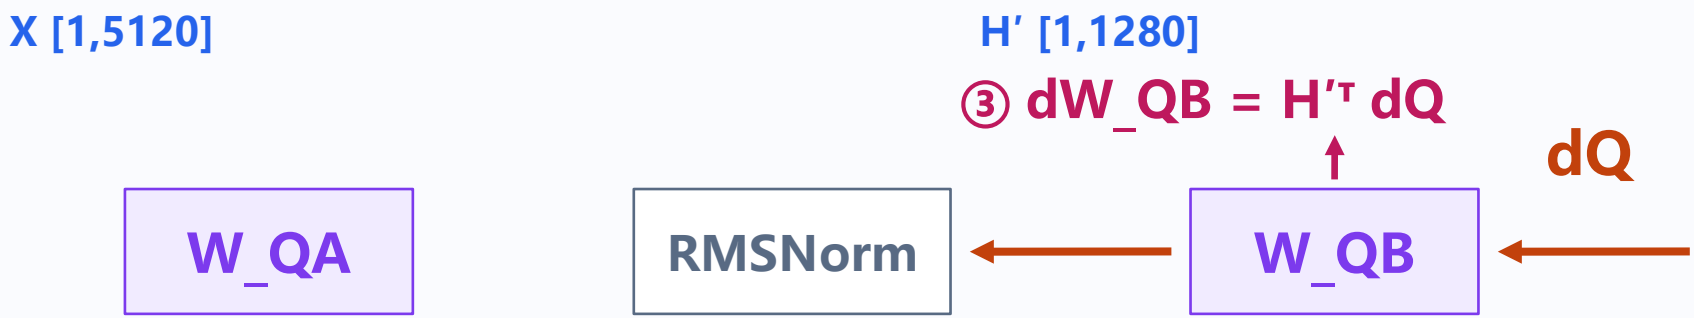


输入 权重 输出 传递梯度 权重梯度

每个 Linear 同时产生两种去向的 Gradient

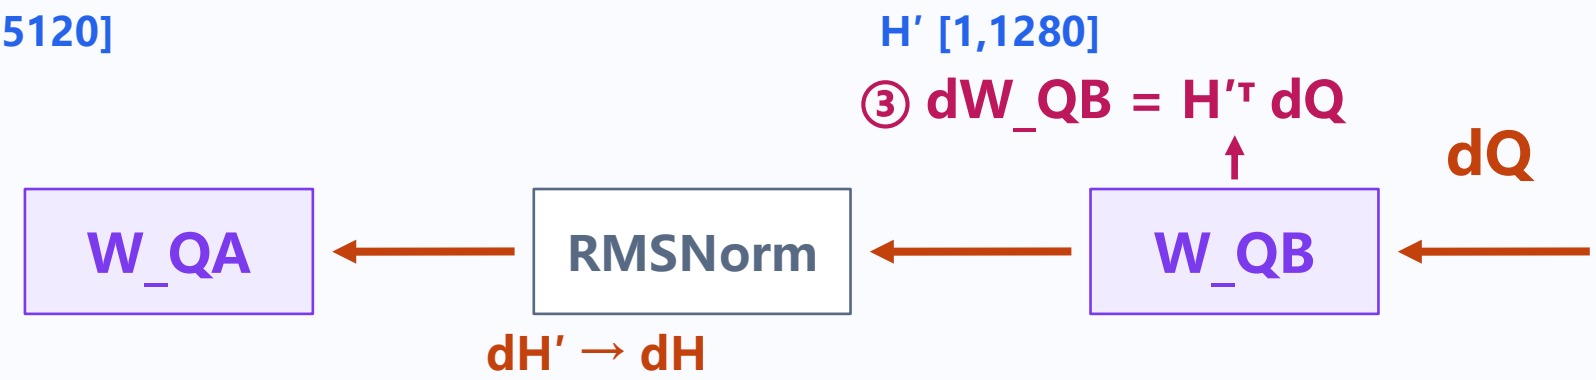


每个 Linear 同时产生两种去向的 Gradient



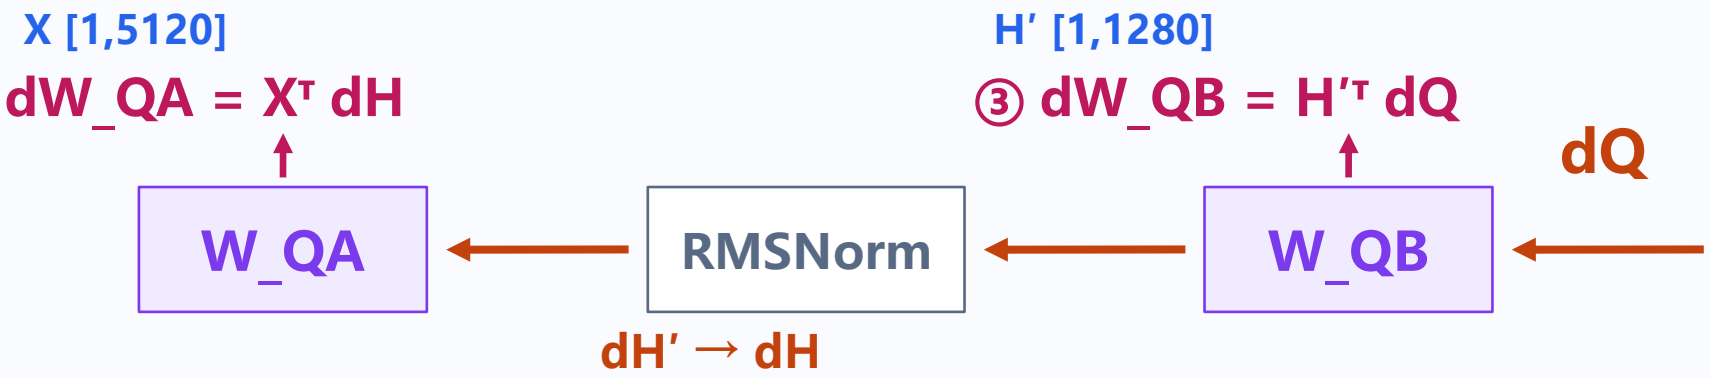
输入 权重 输出 传递梯度 权重梯度

每个 Linear 同时产生两种去向的 Gradient



输入 权重 输出 传递梯度 权重梯度

每个 Linear 同时产生两种去向的 Gradient



[5120,1] × [1,1280] → [5120,1280]

[1280,1] × [1,32768] → [1280,32768]

dX = dH W_QAᵀ

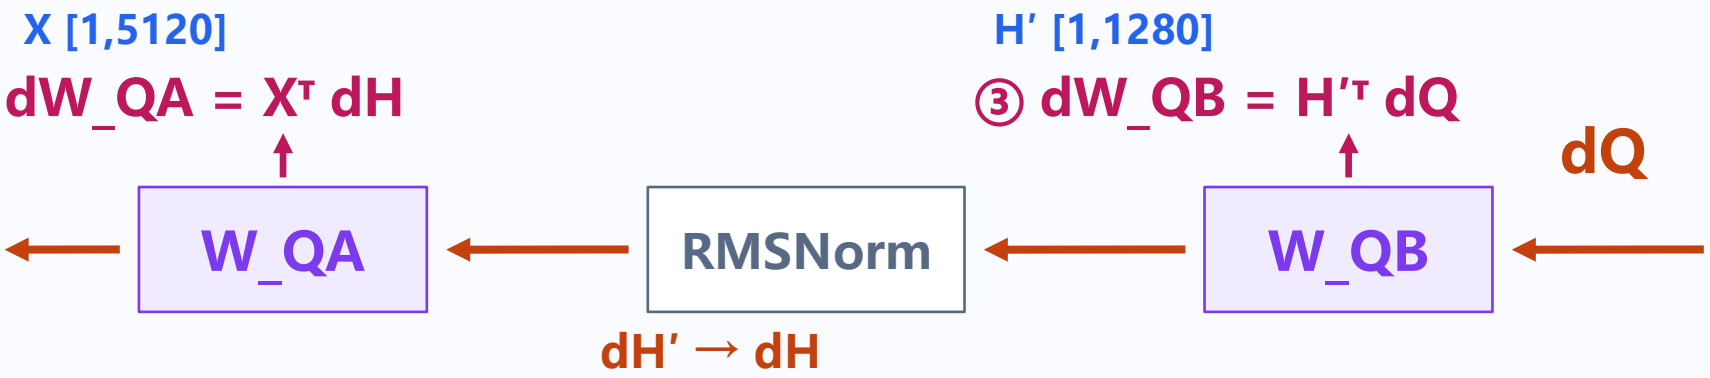
[1,1280] × [1280,5120] → [1,5120]

④ dH′ = dQ W_QBᵀ

[1,32768] × [32768,1280] → [1,1280]

输入 权重 输出 传递梯度 权重梯度

每个 Linear 同时产生两种去向的 Gradient



[5120,1] × [1,1280] → [5120,1280]

[1280,1] × [1,32768] → [1280,32768]

dX = dH W_QAᵀ

[1,1280] × [1280,5120] → [1,5120]

④ dH′ = dQ W_QBᵀ

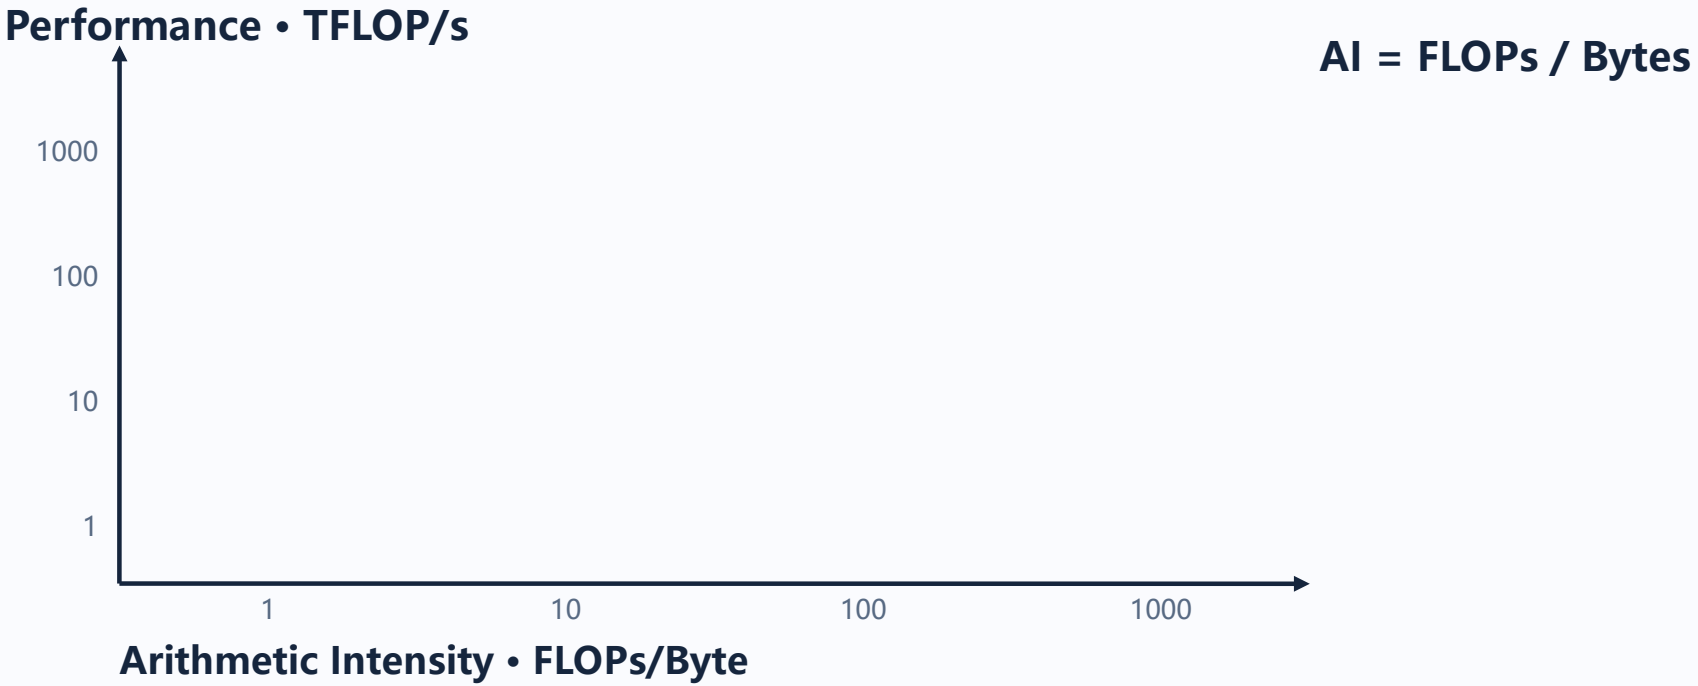
[1,32768] × [32768,1280] → [1,1280]

⑤ dX [1,5120] → 前一模块

输入 权重 输出 传递梯度 权重梯度

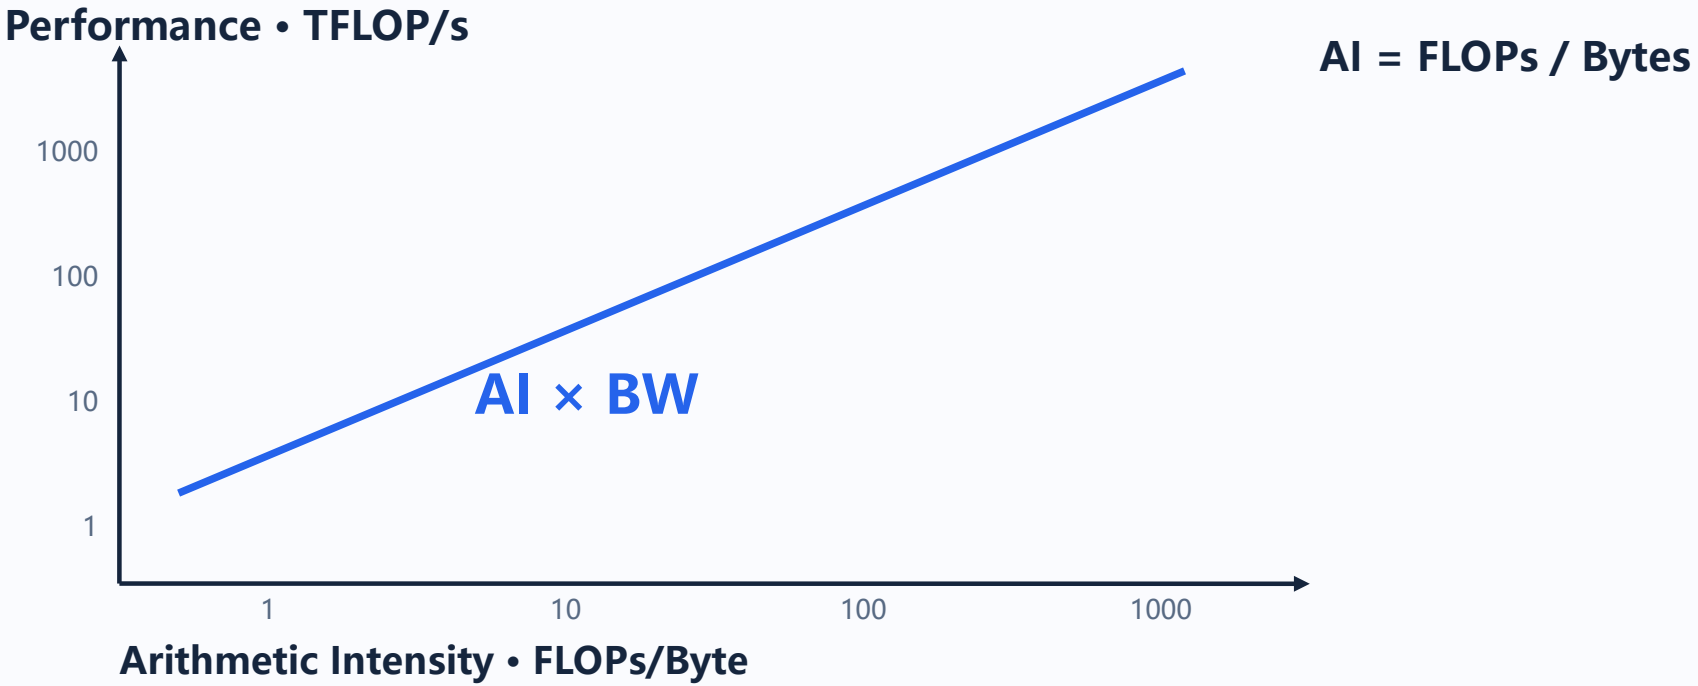
Roofline： 两条上限，共同限定可达性能

Roofline： 两条上限，共同限定可达性能



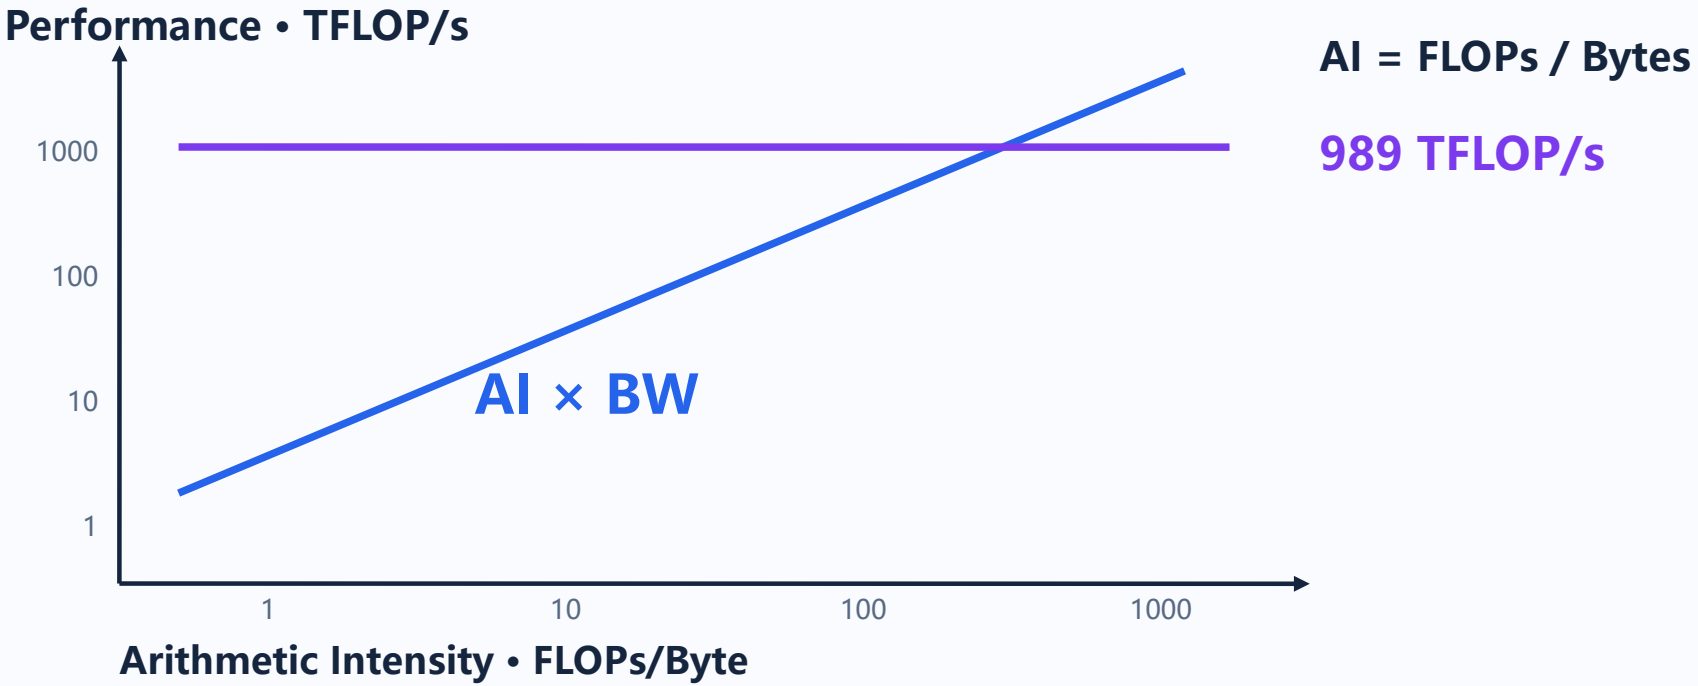
输入 权重 输出 传递梯度 权重梯度

Roofline： 两条上限，共同限定可达性能



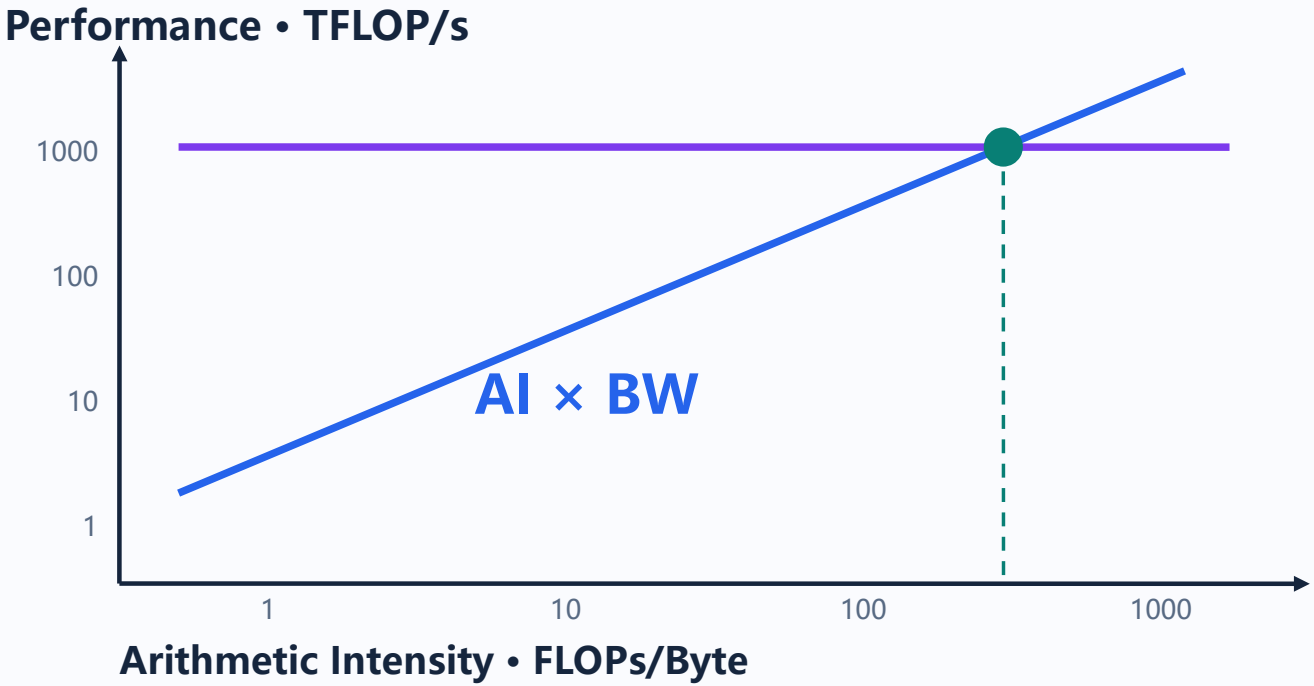
输入 权重 输出 传递梯度 权重梯度

Roofline： 两条上限，共同限定可达性能



输入 权重 输出 传递梯度 权重梯度

Roofline： 两条上限，共同限定可达性能



AI = FLOPs / Bytes

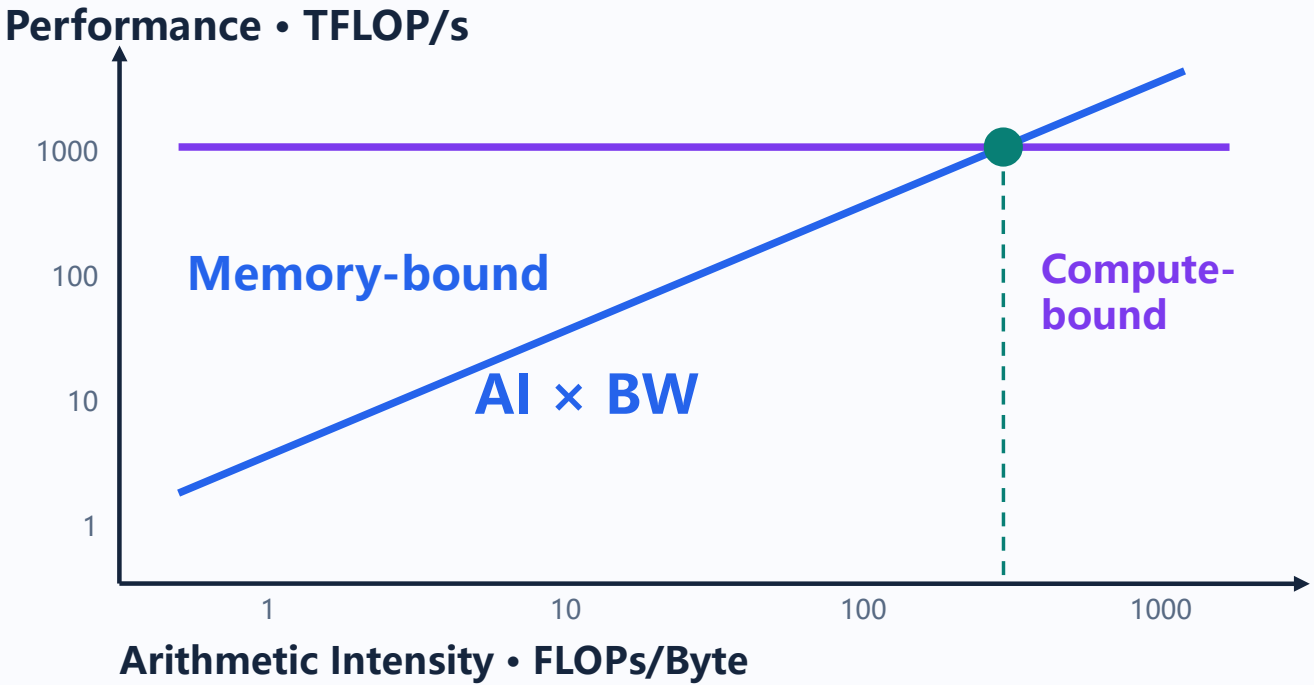
989 TFLOP/s

Ridge ≈ 295.2

P_peak / BW

输入 权重 输出 传递梯度 权重梯度

Roofline： 两条上限，共同限定可达性能



AI = FLOPs / Bytes

989 TFLOP/s

Ridge ≈ 295.2

P_peak / BW

P ≤ min(P_peak, AI × BW)

H100 SXM · BF16 Dense： 989 TFLOP/s， 3.35 TB/s；双对数坐标；理论上界。

输入 权重 输出 传递梯度 权重梯度

MFU： 把有效模型工作量与可用峰值放在同一尺度

Illustrative Example / Not Measured

输入 权重 输出 传递梯度 权重梯度

MFU： 把有效模型工作量与可用峰值放在同一尺度

Illustrative Example / Not Measured

01 Useful Model FLOPs / Step

100.6M tokens × 60 GFLOPs/token **= 6.036 EFLOPs**

输入 权重 输出 传递梯度 权重梯度

MFU： 把有效模型工作量与可用峰值放在同一尺度

Illustrative Example / Not Measured

01 Useful Model FLOPs / Step

100.6M tokens × 60 GFLOPs/token

= 6.036 EFLOPs

02 Total Hardware Peak Throughput

2048 GPUs × 989.5 TFLOP/s

= 2.026496 EFLOP/s

MFU： 把有效模型工作量与可用峰值放在同一尺度

Illustrative Example / Not Measured

01 Useful Model FLOPs / Step

100.6M tokens × 60 GFLOPs/token

= 6.036 EFLOPs

02 Total Hardware Peak Throughput

2048 GPUs × 989.5 TFLOP/s

= 2.026496 EFLOP/s

03 MFU = 6.036 / (6.0 × 2.026496)

49.6%



60 GFLOPs/token 、 2048 GPUs 、 6.0 s： 假设； 989.5： 示例规格

输入 权重 输出 传递梯度 权重梯度