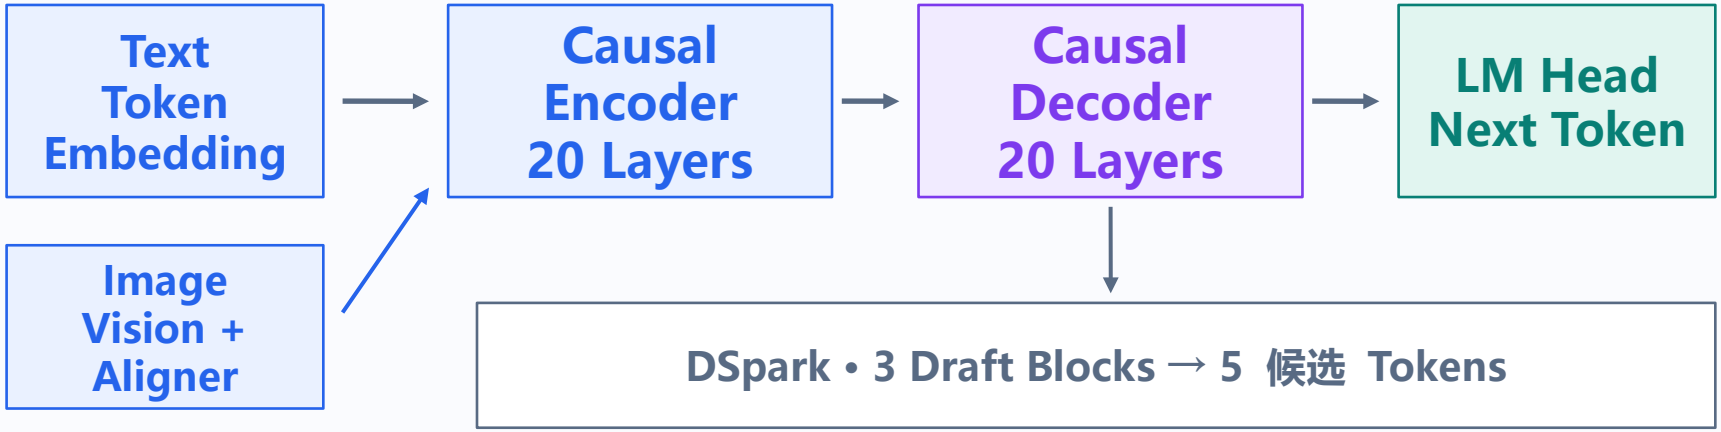
# DeepSeek V4.1 Flash： 计算成本从架构开始

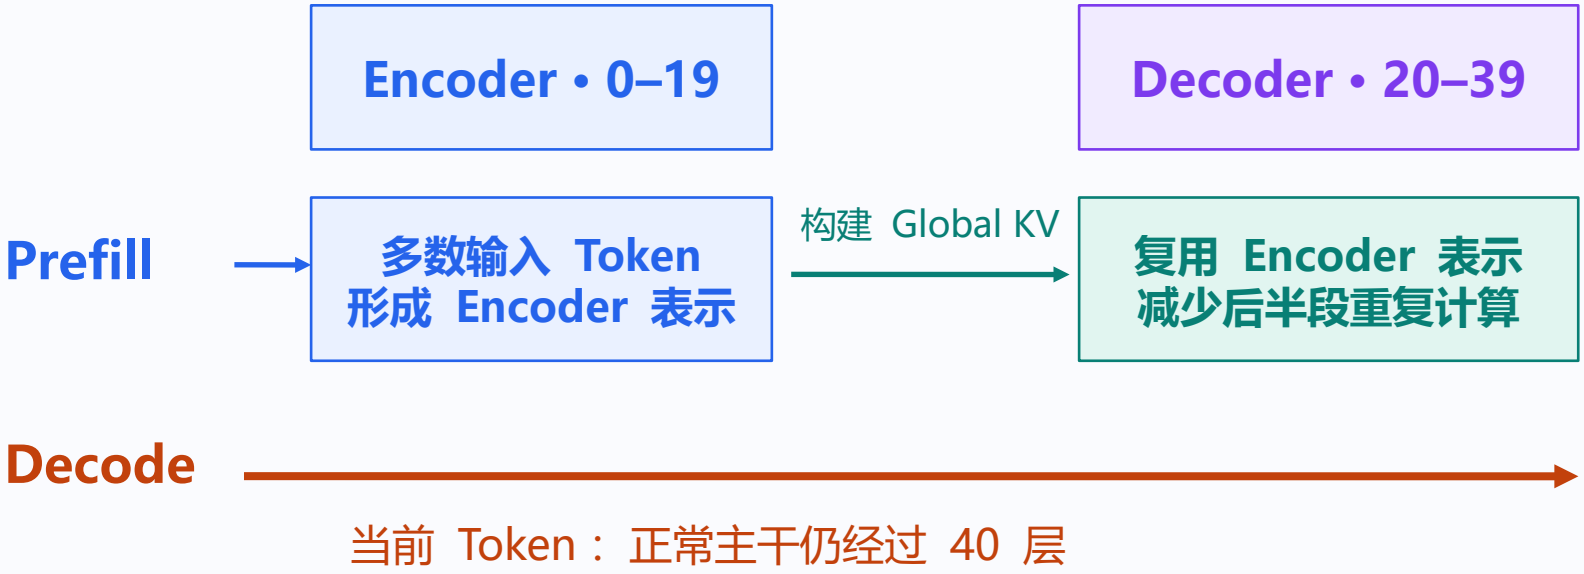
Architecture → Parameters → FLOPs → Efficiency




输入 权重 输出 传递梯度 权重梯度

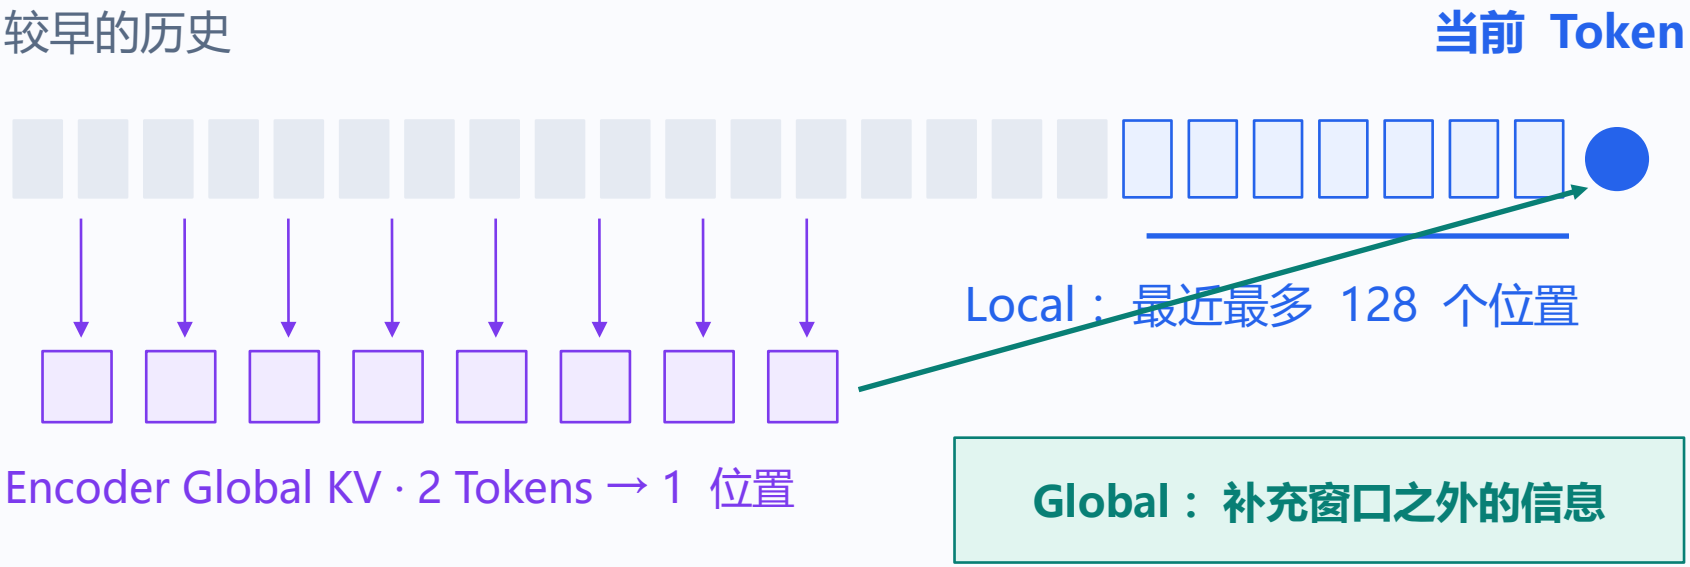
# 20 层 + 20 层：两部分都遵守 Causal Mask

两部分都遵守 Causal Mask；不是传统的双向 Encoder–Decoder 。




输入 权重 输出 传递梯度 权重梯度

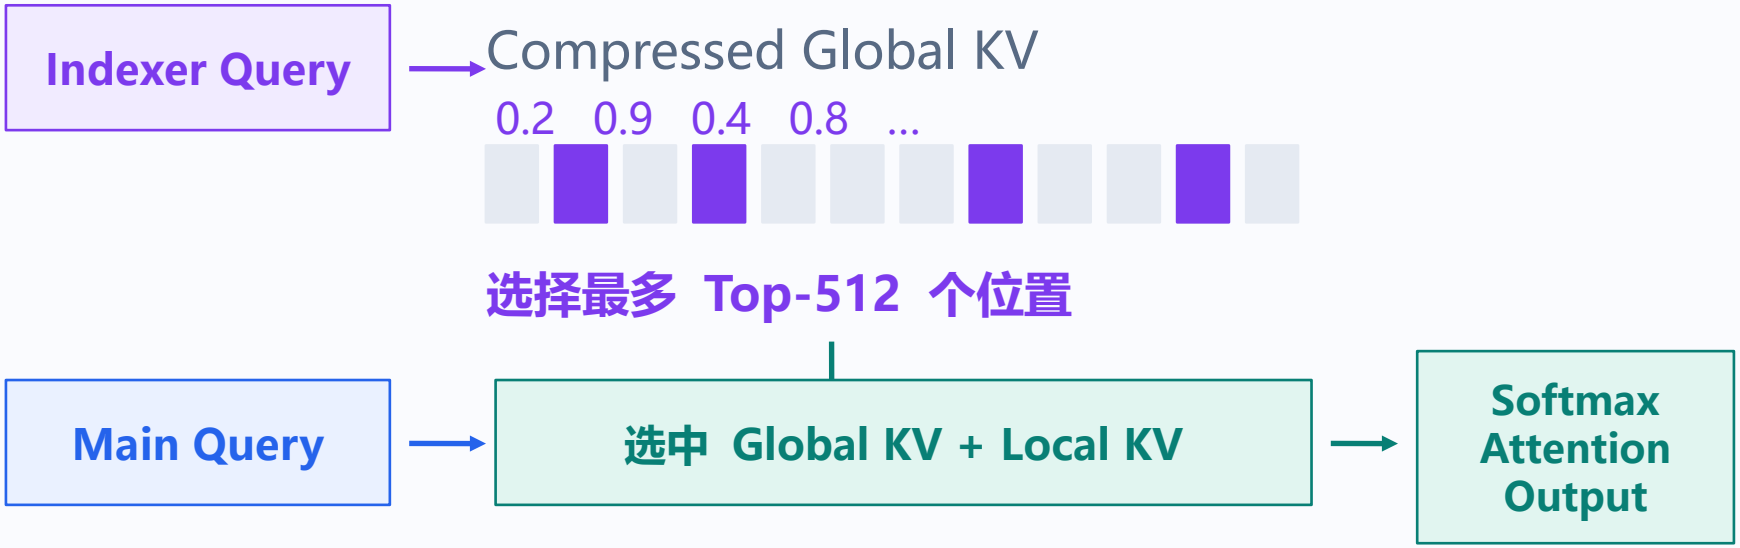
# 局部窗口读取近处，全局路径补充远处




位置数为示意；第 0、1 层仅 SWA，从第 2 层起引入压缩 Global KV。

输入 权重 输出 传递梯度 权重梯度

# Indexer 先选位置， Main Attention 再取信息




Indexer 负责“选位置”， Main Attention 负责“读信息”；两者使用不同的 Query 。

输入 权重 输出 传递梯度 权重梯度

# CSA2：分清 Full、Reindex 与 Reuse

**Full**

新 KV + 新选址

**Reindex**

共享 KV + 新选址

**Reuse**

共享 KV + 共享选址

Encoder




→ 各自后续层复用

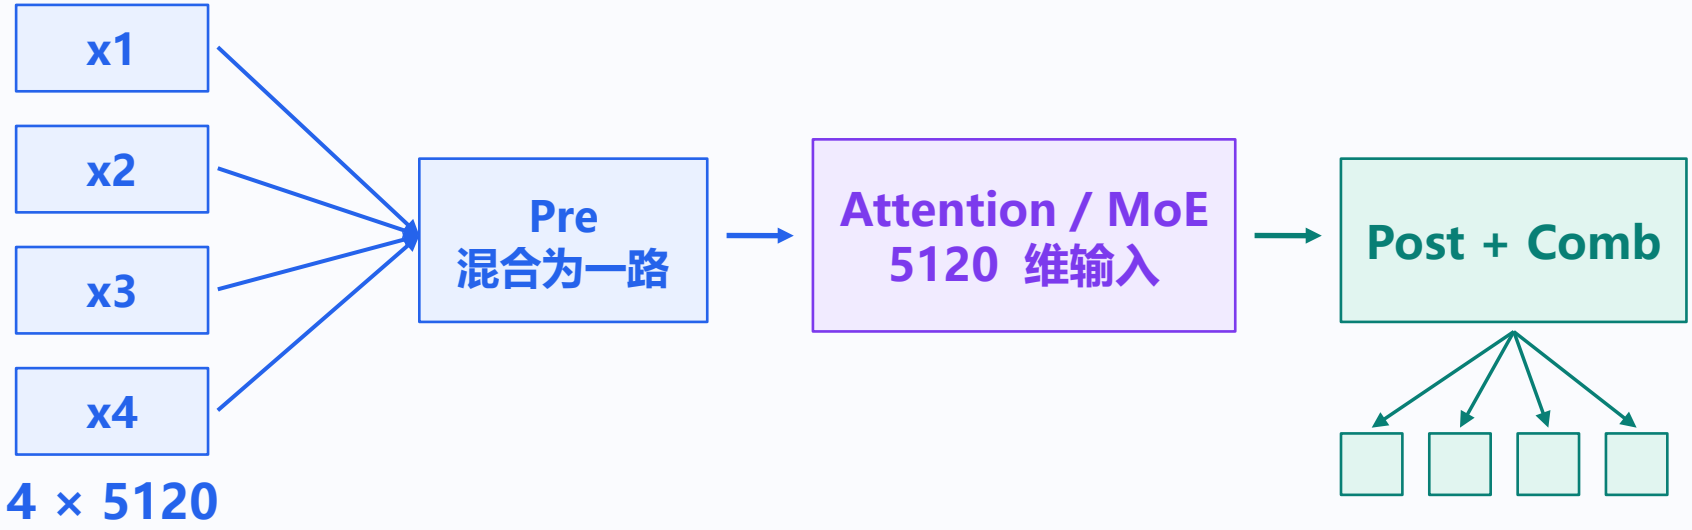
Decoder




Decoder 候选池： 8 positions/block，最多 2048 blocks；层号从 0 开始。

输入 权重 输出 传递梯度 权重梯度

# mHC： 四路残差信息，一路主模块计算




四路状态在主模块前汇合；主模块输出再分配，与残差信息组合。

输入 权重 输出 传递梯度 权重梯度

# Dense 使用同一组 FFN； MoE 选择执行路径

## Dense FFN

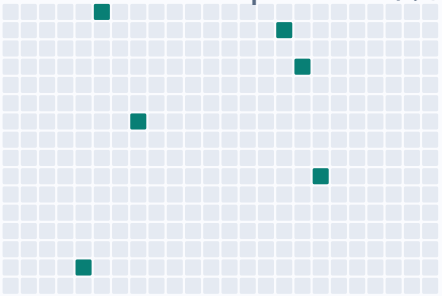
Token → 同一组 FFN

所有输入使用同一组权重

## Mixture of Experts

Token → Router

384 Routed Experts · 评分示意



Scores
0.12 · 0.91 · …

Top-6

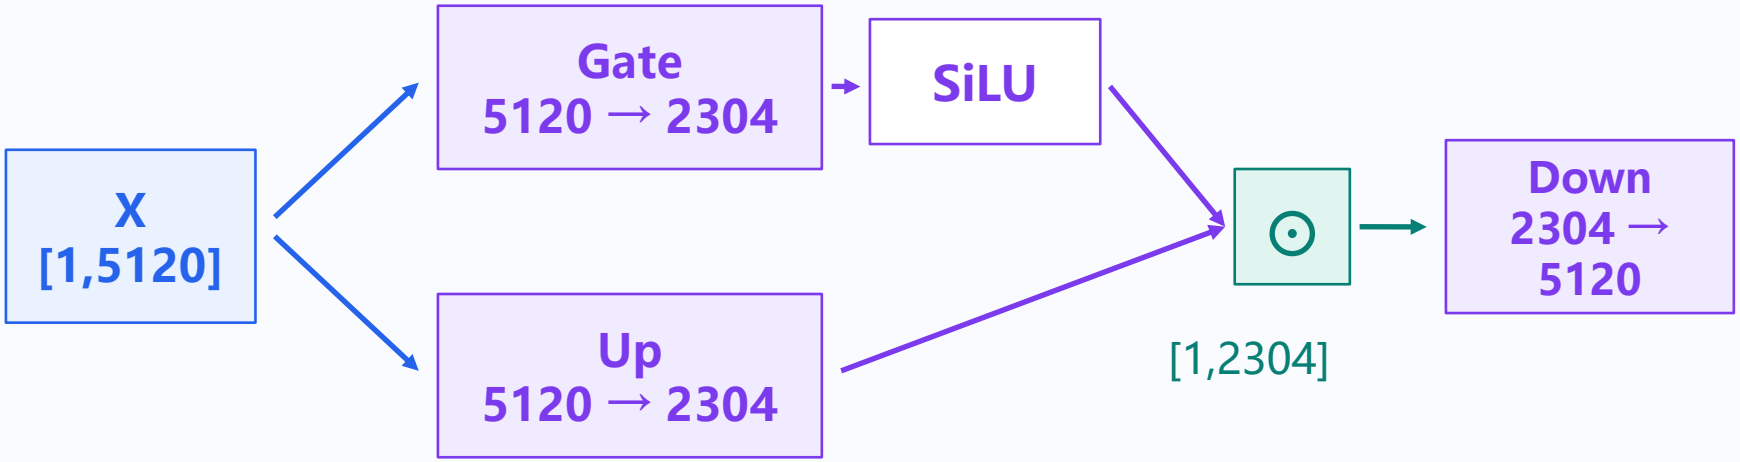
1 Shared

6 × Expert FFN

$\Sigma \alpha_i \, \text{Expert}_i(x) + \text{Shared}(x)$

输入 权重 输出 传递梯度 权重梯度

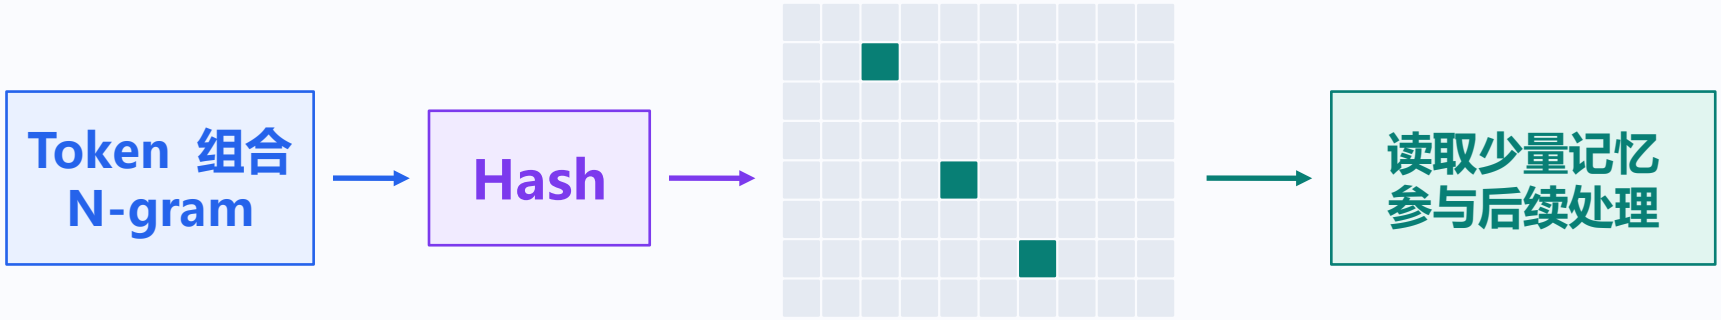
# 一个 Expert： Gate、 Up、 Down 三个投影




三个 Linear； SiLU 与逐元素乘法无新增可学习参数，但仍有计算成本。

输入 权重 输出 传递梯度 权重梯度

# Engram： 按局部 token 组合查找条件记忆

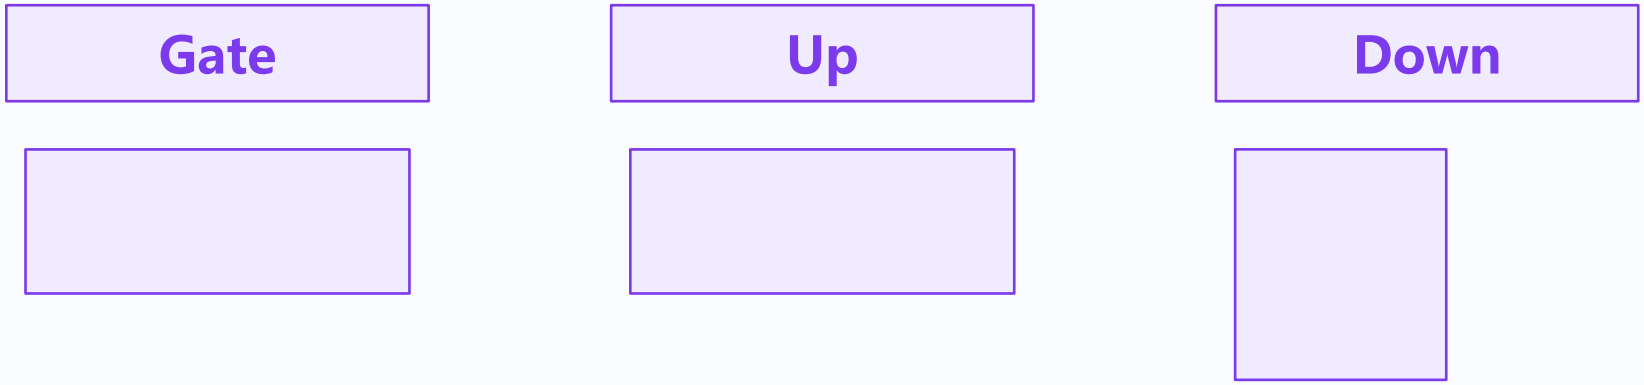



放置于 Encoder 第 1、 14 层；图示为检索直觉，不是完整 Engram 内部实现。

输入 权重 输出 传递梯度 权重梯度

# 从矩阵形状数参数：一个 Expert 约 3540 万

三个 Linear 均无加性 Bias




$$P(\text{Expert}) = 3 \times 5120 \times 2304 = 35{,}389{,}440$$

输入 权重 输出 传递梯度 权重梯度

# 保存 385 个专家，每个 token 使用其中 7 个

## Total Parameters



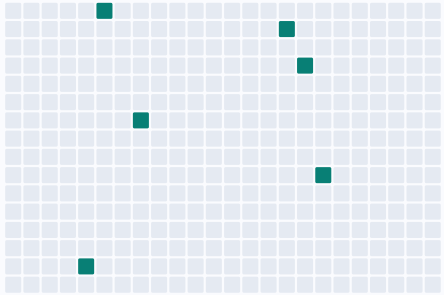
+ Shared

**13,624,934,400**

**385 × 35,389,440**

+ Router 1,966,080 → 约 136.27 亿

## Active Parameters / Token



+ Shared

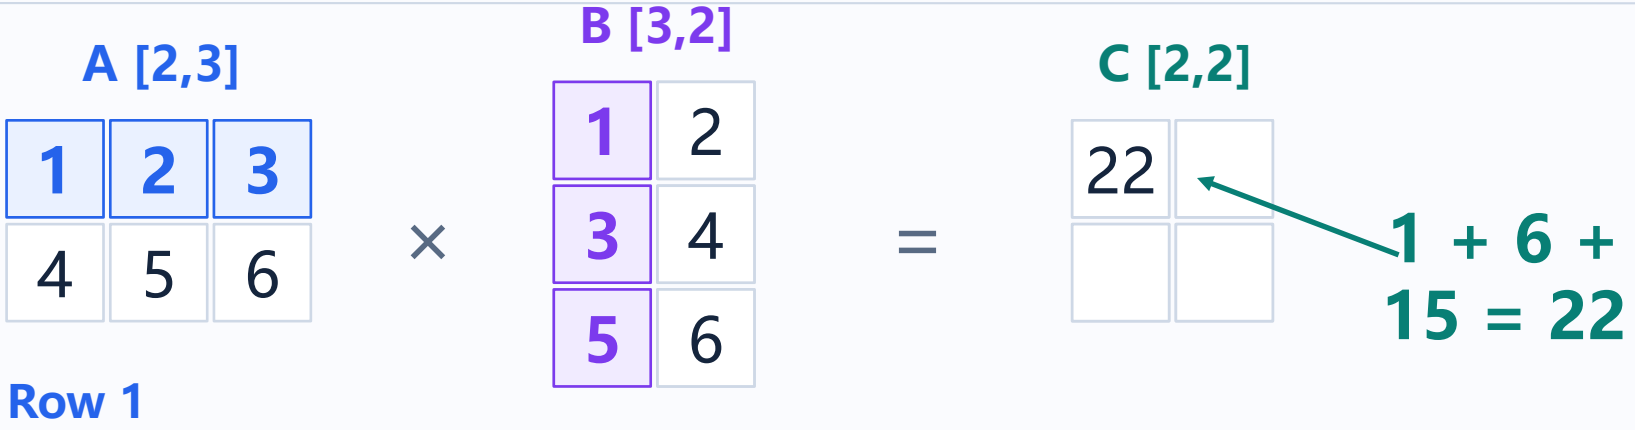
**247,726,080**

**7 × 35,389,440**

+ Router → 约 2.50 亿

输入 权重 输出 传递梯度 权重梯度

# Matrix Multiplication： 一行 × 一列，生成一个数




每次只生成 C 中的一个元素

# 换一列，得到下一个输出；重复同样的规则



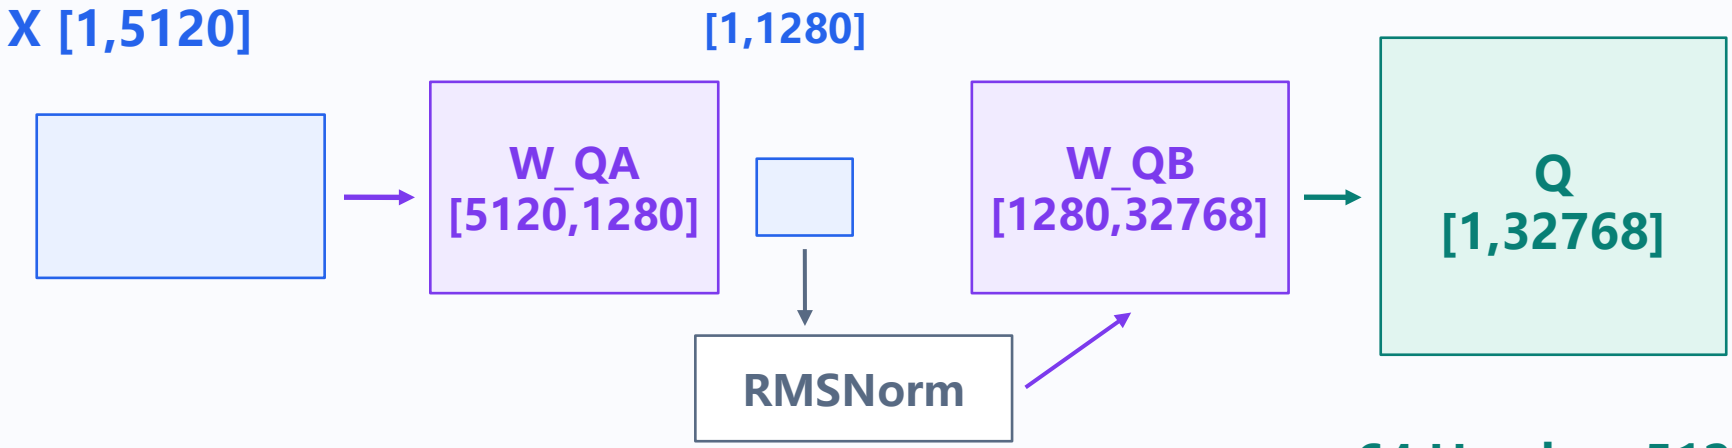

$$1 \times 2 + 2 \times 4 + 3 \times 6 = 28$$

**一个输出： K 次乘法 + (K−1) 次加法**

本例精确： 4 × 5 = 20 FLOPs　　常用近似： 2MKN = 24 FLOPs

输入　权重　输出　传递梯度　权重梯度

# Query Low-Rank Projection： 先压缩，再展开



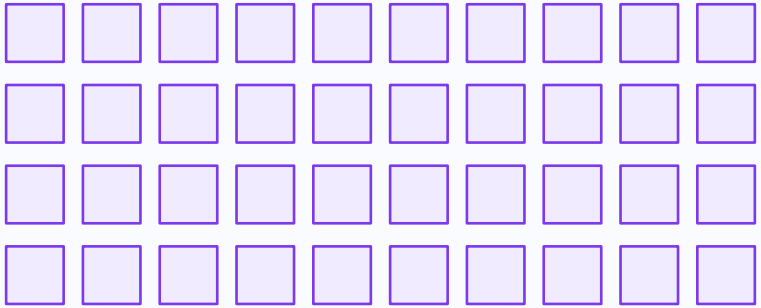

宽度为示意； FLOPs 不含 RMSNorm / RoPE

输入 权重 输出 传递梯度 权重梯度

# 40 层 Query 投影：约 3.88 GFLOPs

正常主干 Decode ； 只含 Query 的两个 Linear ， 其余模块仍需另计。

**1 Layer**
**96.99**
**MFLOPs**



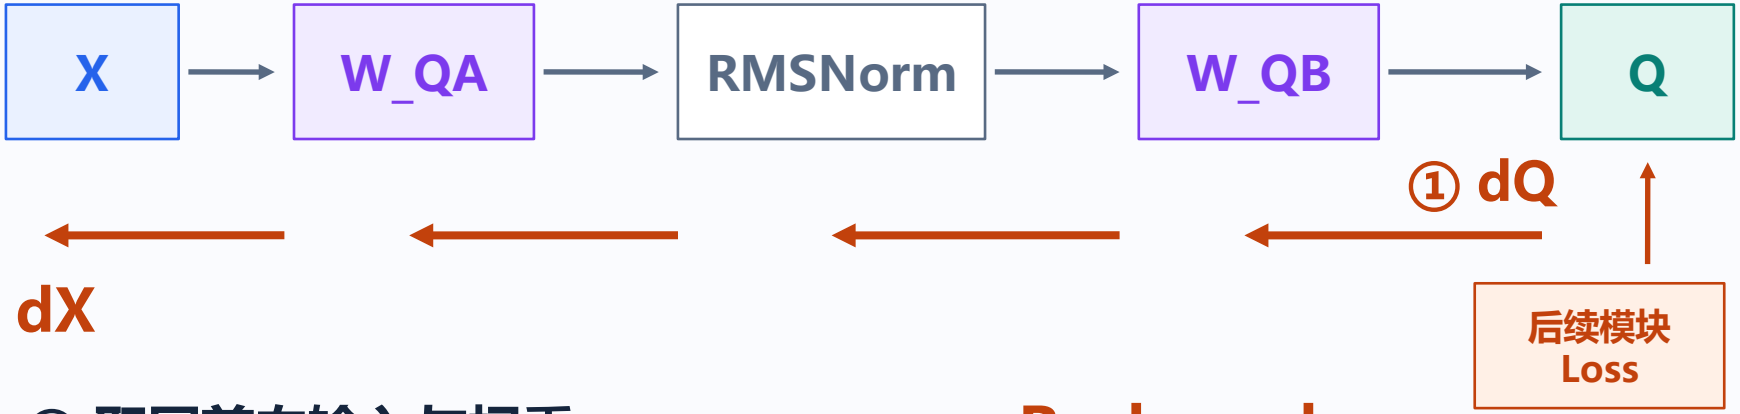
**40 次同形状 Query 投影**

**≈ 3.8797 GFLOPs**

输入 权重 输出 传递梯度 权重梯度

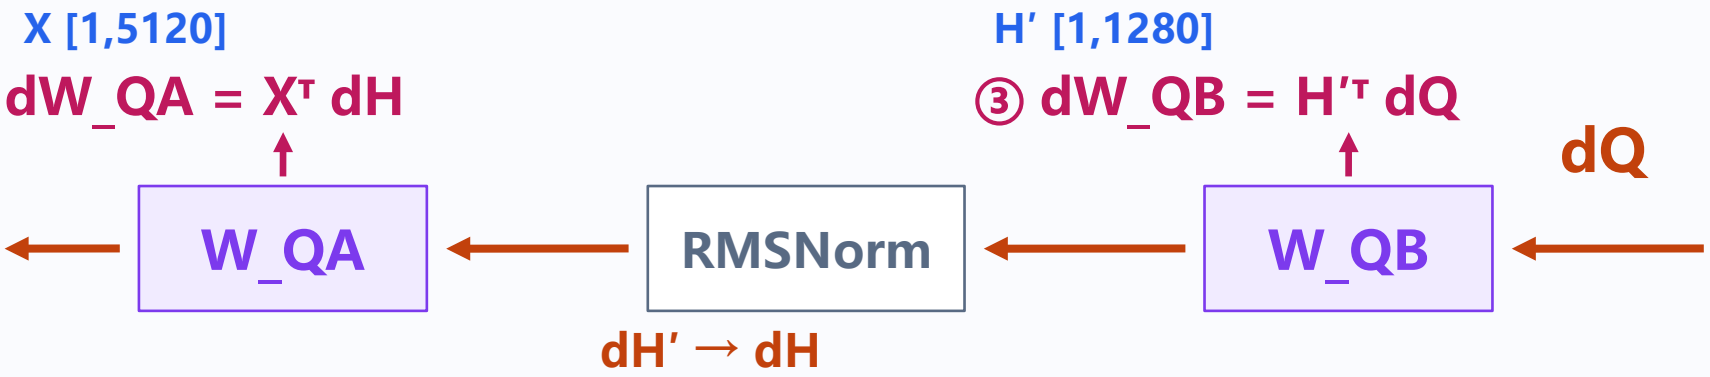
# Forward 保存输入； Backward 沿图反向传梯度

**Forward →** 保存 X 、 H 、 H′ 与各层权重




输入 权重 输出 传递梯度 权重梯度

# 每个 Linear 同时产生两种去向的 Gradient




[5120,1] × [1,1280] → [5120,1280]

[1280,1] × [1,32768] → [1280,32768]

**dX = dH W_QAᵀ**

[1,1280] × [1280,5120] → [1,5120]

**④ dH′ = dQ W_QBᵀ**

[1,32768] × [32768,1280] → [1,1280]

**⑤ dX [1,5120] → 前一模块**

输入 权重 输出 传递梯度 权重梯度

# 两次梯度矩阵乘法，让 Linear 反向约为前向两倍

前向 + 反向 ≈ 290.98 MFLOPs；不含 RMSNorm 、优化器或额外重计算。

**Forward**



**F ≈ 2MKN**

**Backward**



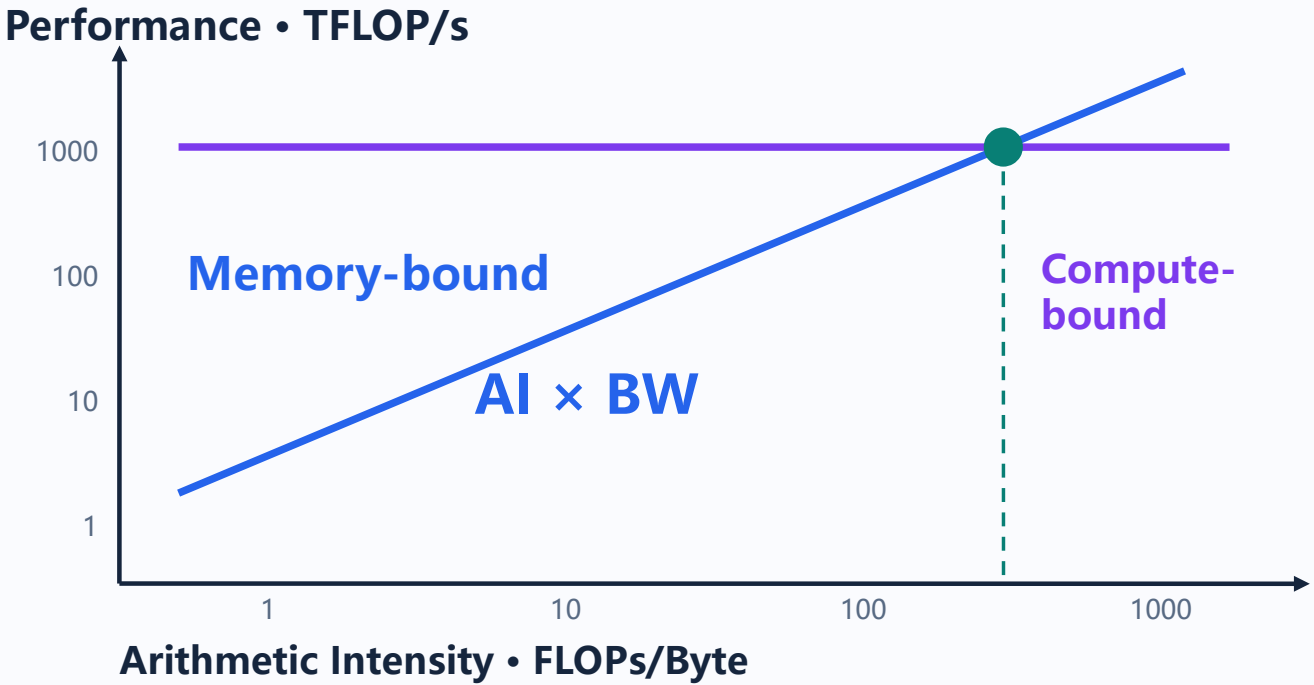
**dW** **dX**

## Query Linear Backward ≈ 193.99 MFLOPs

单 token 精确外积计数不同；“两倍”是统一 2MKN 近似。

输入 权重 输出 传递梯度 权重梯度

# Roofline： 两条上限，共同限定可达性能




AI = FLOPs / Bytes

989 TFLOP/s

Ridge ≈ 295.2

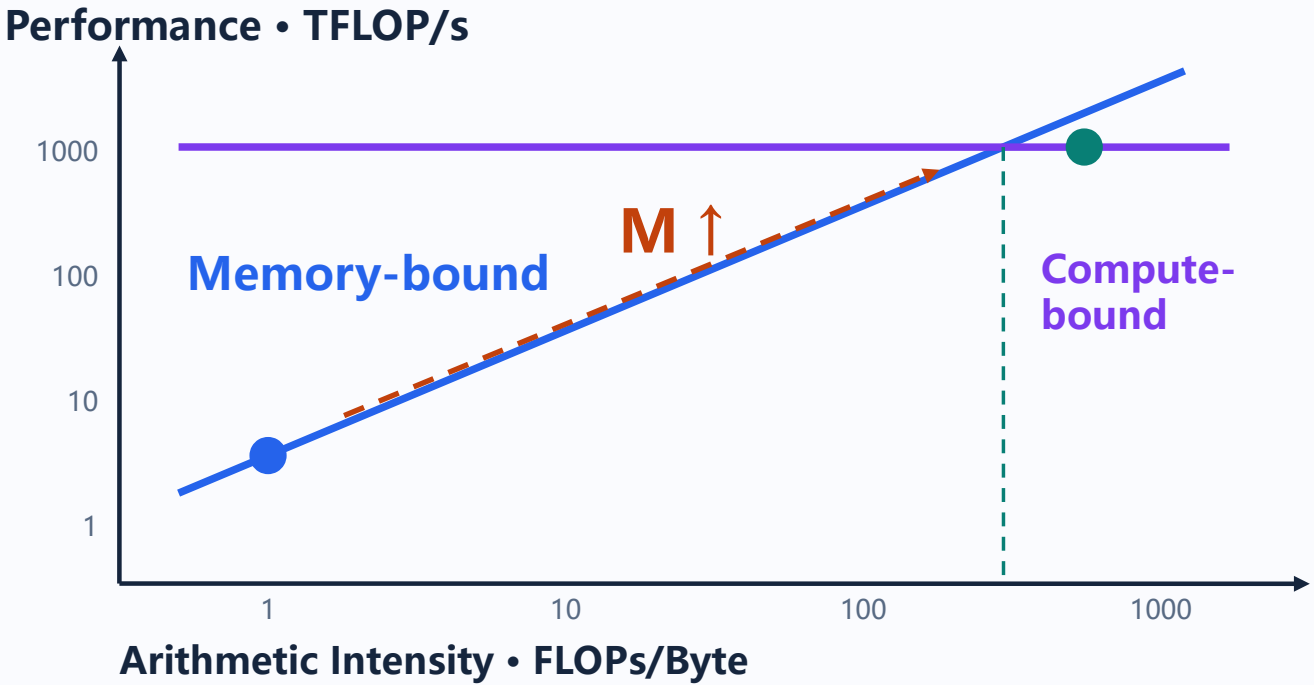
P_peak / BW

P ≤ min(P_peak, AI × BW)

H100 SXM · BF16 Dense： 989 TFLOP/s， 3.35 TB/s；双对数坐标；理论上界。

输入 权重 输出 传递梯度 权重梯度

# 权重复用提高 Arithmetic Intensity，点向右移动




BF16 • 2 Bytes

权重按批次读一次
H 写出一次、读回一次

M=1
96.99 MFLOPs
97.07 MB • AI≈1

M=1024
99.32 GFLOPs
179.83 MB
AI≈552.3

只含两个 Query Linear；简化流量模型，非实测； M 为一次共同处理的行数。

输入 权重 输出 传递梯度 权重梯度

# MFU： 把有效模型工作量与可用峰值放在同一尺度

**Illustrative Example / Not Measured**

## 01 Useful Model FLOPs / Step

100.6M tokens × 60 GFLOPs/token

**= 6.036 EFLOPs**

## 02 Total Hardware Peak Throughput

2048 GPUs × 989.5 TFLOP/s

**= 2.026496 EFLOP/s**

## 03 MFU = 6.036 / (6.0 × 2.026496)

**49.6%**



60 GFLOPs/token 、 2048 GPUs 、 6.0 s： 假设； 989.5： 示例规格

输入 权重 输出 传递梯度 权重梯度

# 沿着计算路径，把成本与效率接起来




哪些路径执行
哪些权重被访问

前向 + 反向
声明范围与计数口径

**Roofline： 潜在瓶颈　　MFU： 有效训练吞吐 / 总峰值**

输入　权重　输出　传递梯度　权重梯度